パターン情報学　プログラミングレポート課題

03-140299 東京大学機械情報工学科 3 年 和田健太郎

2015 年 2 月 10 日

1　課題 1

課題 1

2 クラス（$\omega 1$，$\omega 2$）の識別問題を考える．データは 2 次元とする．配布するデータセットの説明を以下に示す．

- Train1.txt，Train2.txt：$\omega 1$，$\omega 2$ に属する訓練データ集合．各データ数 50.
- Test1.txt，Test2.txt： $\omega 1$，$\omega 2$ に属するテストデータ集合．各データ数 20.

2 クラスで，2 次元のデータに対するウィドロー・ホフのアルゴリズムを実装し，訓練データから分離超平面を学習せよ．また，テストデータの識別率（全テストデータ数に対する正しく識別されたテストデータ数の比率）を求めよ．さらに，訓練データ，テストデータ，学習された識別面を図示せよ．

ウィドロー・ホフのアルゴリズムを初期の重みはランダムとし, 指定した回数だけ繰り返し重みの更新を行うように実装した.

2 次元の訓練データ 100 件を用いて識別器の学習を行い, 40 件のテストデータで性能を測定したところ, 0.875 という結果が出た.

また, 訓練データ, テストデータのそれぞれ 2 クラスと識別面を図示したものが図 1 である.

2　課題 2

課題 2

擬似逆行列を計算するプログラムを書き，課題 1 と同じ訓練データから分離超平面を学習せよ．また，テストデータの識別率を求めよ．クラスラベルについて，$\omega 1$ に属するものを 1，$\omega 2$ に属するものを-1 などとせよ．さらに，学習された識別面を課題 1 と同じ図に示せ．

擬似逆行列を数値計算ライブラリである numpy を利用して実装した.

$$A^{+} = (A^{T} \cdot A)^{-1} \cdot A^{T}$$

擬似逆行列を用いて訓練データに関して重みを計算し, テストデータによって識別性能を測定したところ, 1 と同様に 0.875 という結果だった.

訓練データ, テストデータおよび識別面を図示したものが図 2 で, 識別面の位置をウィドロー・ホフのアルゴリズムによるものと比べてみると, ほぼ同じ位置にあることがわかる.

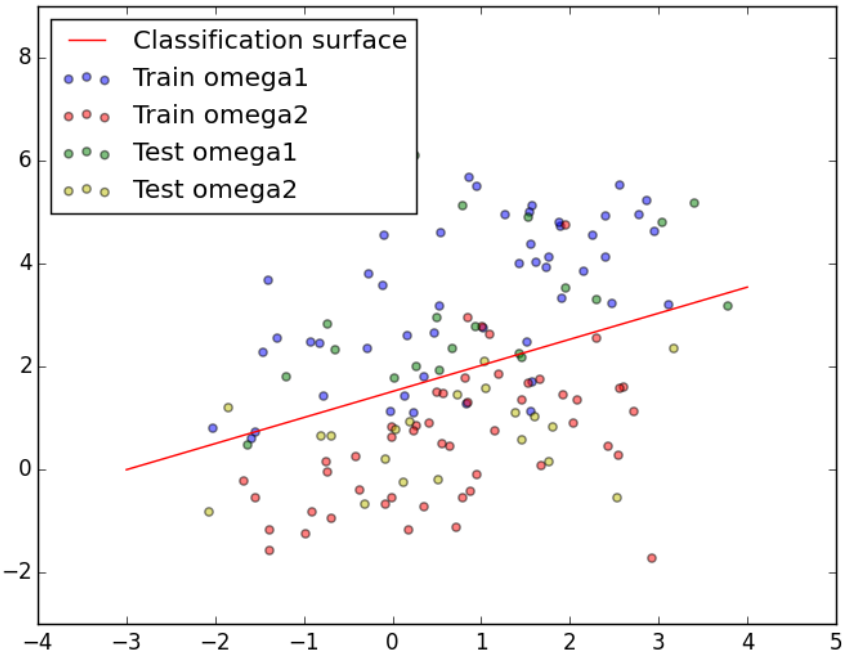

図 1: データおよび識別面

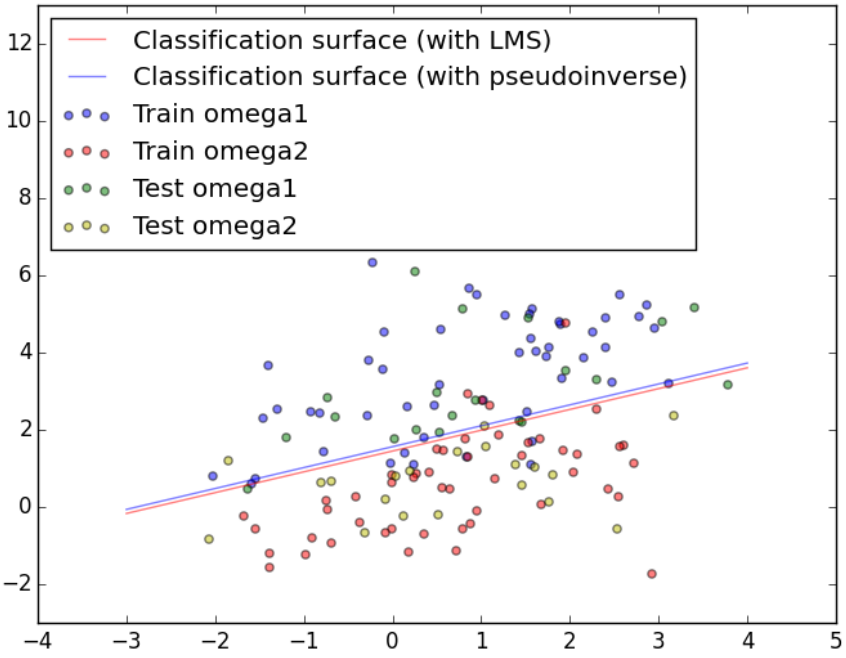

図 2: データおよび識別面

3　課題 3

課題 3

本課題も課題 1 と同じデータセットを利用する.

1. テストデータの集合を k 近傍法 (kNN) を用いて識別することを考える． 訓練データに対して一つ抜き出し, (LOO: leave-one-out) 法により k の値を 1 から 10 まで変化させ，最適な k の値を求めよ．また，横軸に k， 縦軸に識別率としてグラフを作成せよ.

2. LOO により得られた k の値を用いてテストデータを識別せよ．そして，識別率を求めよ.

訓練データに対して LOO により識別を行い, k の値を 1 から 10 まで変化させて識別率を測定した. その関係を示したのが図 3 である. 図 3 より,k が 3 の時に最も識別性能が高くなっていることがわかる.

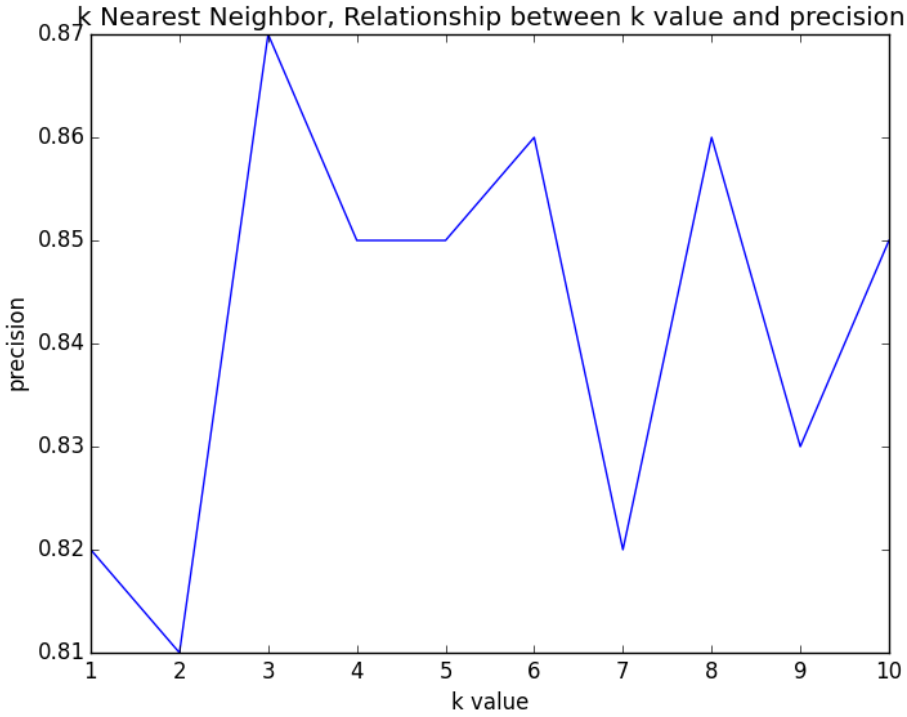

図 3: k 値と LOO 法による kNN の識別率の関係

4 課題 4

課題 4

表にあるデータを利用する．また潜在的な確率密度分布は正規分布であるとする．P(ωi)=1/3 とする．表にあげた各クラスのデータセットは omega1.txt，omega2.txt，omega3.txt である．このとき次の問いに答えよ．

1. テスト点：$(1,2,1)^T$, $(5,3,2)^T$, $(0,0,0)^T$, $(1,0,0)^T$ と各クラスの平均との間のマハラノビス距離を求めよ．
2. これらの点を識別せよ．
3. 次に P(ω_1)=0.8 かつ P(ω_2) = P(ω_3)=0.1 と仮定し，テスト点をもう一度識別せよ

テスト点：$(1,2,1)^T$, $(5,3,2)^T$, $(0,0,0)^T$, $(1,0,0)^T$ に関して, 各クラス集合の平均とのマハラノビス距離

$$M_D(x) = \sqrt{(x-\mu_i)^T \sum (x-\mu_i)} \tag{1}$$

を表 1 に計算した.

sample points	ω_1	ω_2	ω_3
$(1,2,1)^T$	1.0149706212	0.85805119543	2.67475703681
$(5,3,2)^T$	1.557138211	1.75568068865	0.647009014093
$(0,0,0)^T$	0.489961541569	0.268432411153	2.24150137149
$(1,0,0)^T$	0.487236758687	0.451834352153	1.46233640166

表 1: テスト点の各クラス集合の平均とのマハラノビス距離

確率的生成モデルを用いて, これらのテスト点を識別したところ, 表 2 に示す識別結果となった. ($P(\omega_i) = 1/3$)

$P(\omega_1) = 0.8$, $P(\omega_2) = P(\omega_3) = 0.1$ として識別を行ったところ表 3 に示す識別結果となり, ω_1 にすべてのテスト点が分類されるものとなった.

$(1,2,1)^T$	$(5,3,2)^T$	$(0,0,0)^T$	$(1,0,0)^T$
ω_1	ω_3	ω_1	ω_1

表 2: $P\omega_i = 1/3$ での識別結果

$(1,2,1)^T$	$(5,3,2)^T$	$(0,0,0)^T$	$(1,0,0)^T$
ω_1	ω_1	ω_1	ω_1

表 3: $P\omega_1 = 0.8$, $P\omega_2 = P\omega_3 = 0.1$ での識別結果

5　チャレンジ課題 1

チャレンジ課題 1

主成分分析, 多クラスフィッシャー判別分析を実装せよ. また,3 クラス,4 次元の iris データセット iris.txt に主成分分析とフィッシャー判別分析をそれぞれ適応して 1 次元に次元削減し図示せよ. 次元削減後のクラス間デー タの分離の違いを確認せよ. なお iris データセットの各行はデータのインデックス, 第 5 列はクラス番号 (1,2, 3 クラス) を示している. 各クラス 50 サンプル合計 150 サンプルとなる.

主成分分析とフィッシャー線形判別による特徴空間の変換結果を 4 に示す.

PCA に比べ FisherLDA ではクラス 1 とクラス 2,3 とのクラス間分散が大きくなり, クラス 3 のクラス内分散が小さくなっていることがわかる. また, クラス 2,3 の重なりも FisherLDA の方が小さくなっている.

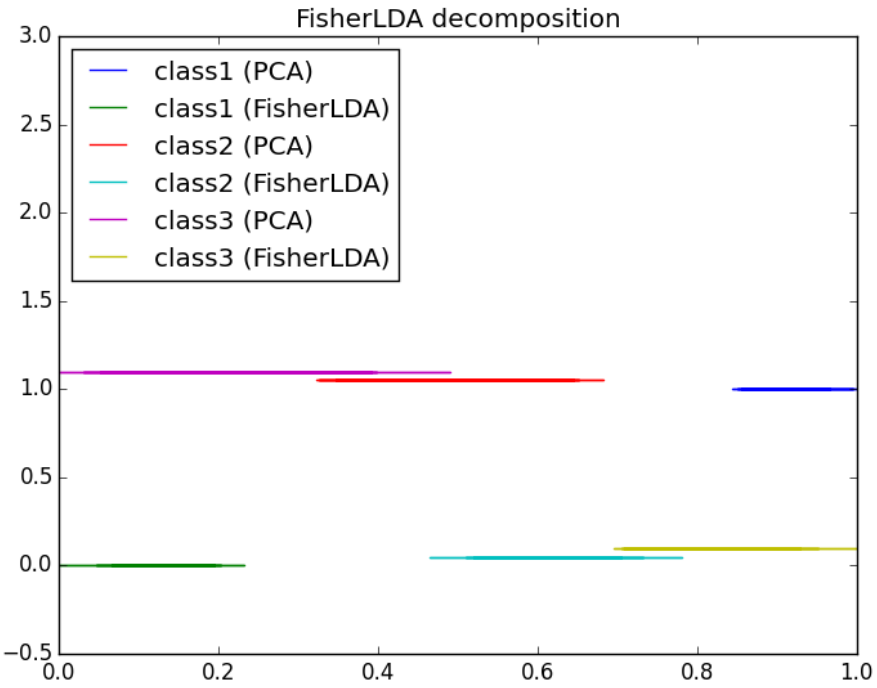

図 4: PCA と FisherLDA による特徴空間の変換 (データ:iris.txt)

6　チャレンジ課題 2

チャレンジ課題 2

ロジスティック回帰を実装し, 課題 1 のデータに適用してテストデータの識別率を求めよ.

ロジスティック回帰を実装したところ, 境界面は図 5 のようになり, 識別率は 0.875 であった.

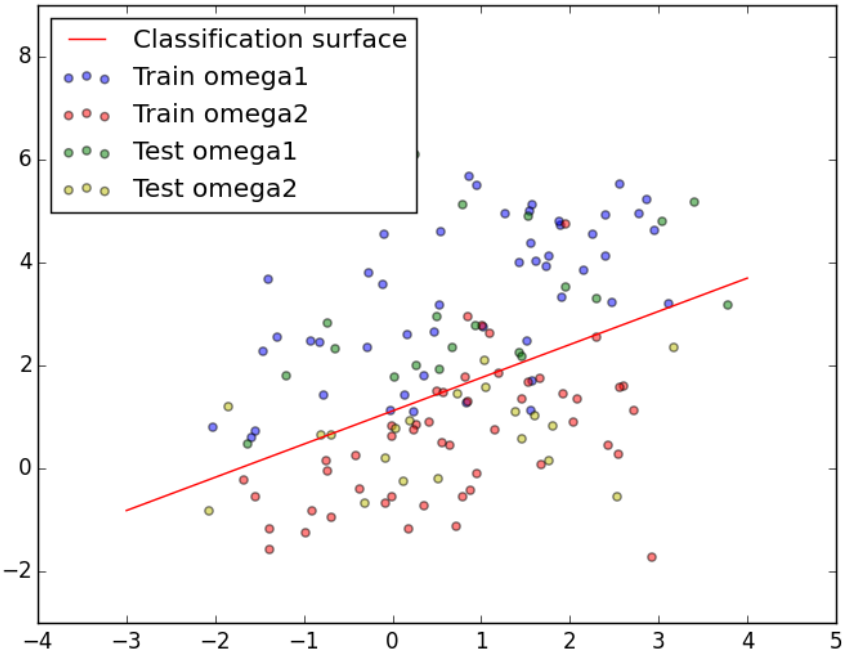

図 5: ロジスティック回帰分析結果